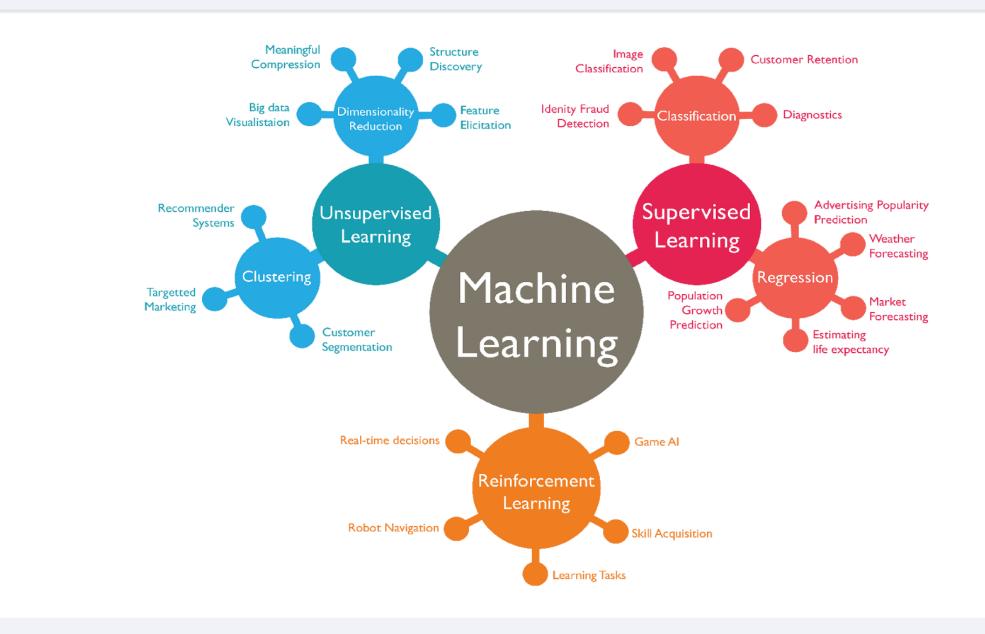
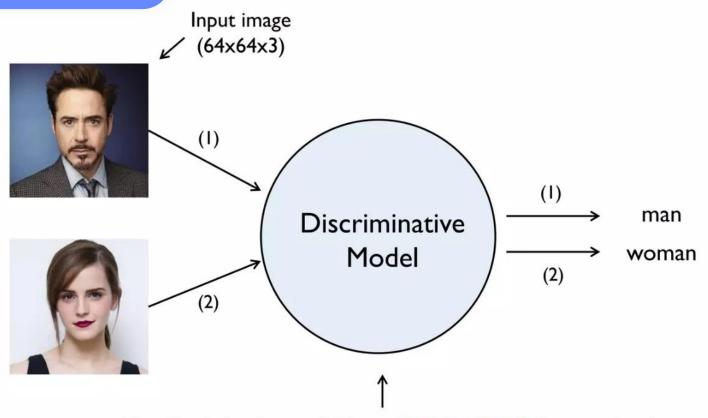
GAN

황주훈

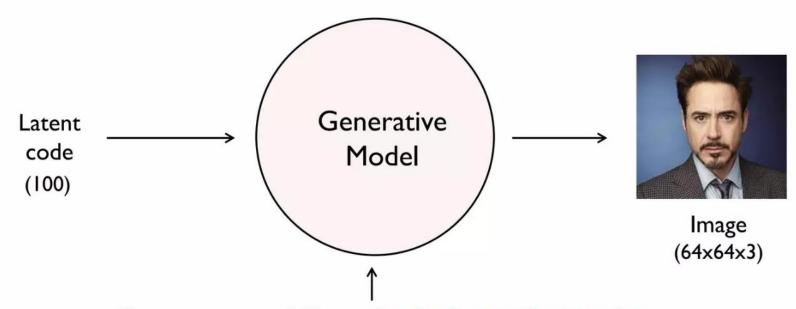


Supervised Learning



The discriminative model learns how to classify input to its class.

Unsupervised Learning



The generative model learns the distribution of training data.

확률분포

- 확률분포는 확률 변수가 특정한 값을 가질 확률을 나타내는 함수
- 예를 들어 주사위를 던졌을때 나올 수 있는 수를 확률변수 X라고 합시다.
 - 확률변수 X는 1, 2, 3, 4, 5, 6
 - P(X = 1) = 1/6

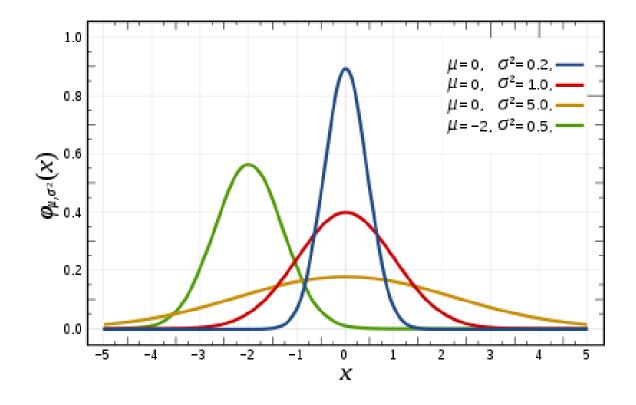
$X = x_i$	1	2	3	4	5	6	합
$P(X=x_i)$	1	1	1	1	1	1	1
	6	6	6	6	6	6	

이산확률분포

• 확률변수 X의 는 개수는 정확히 셀 수 있을 때 **이산확률분포**라한다.

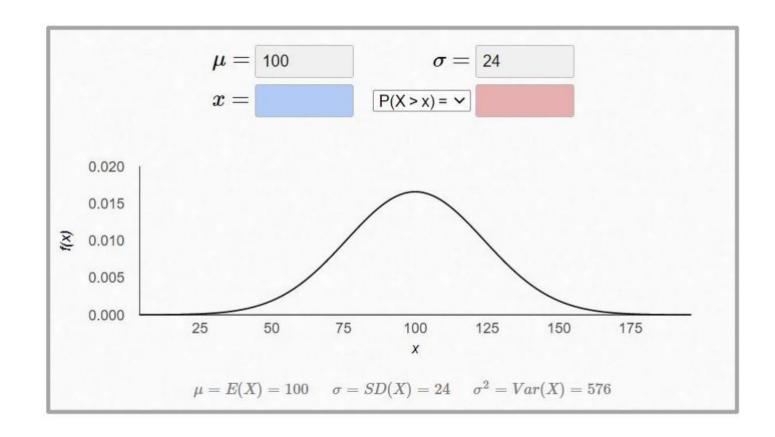
연속확률분포

- 확률변수 X의 는 개수는 정확히 셀 수 없을 때 연속확률분포라한다
- 연속적인 값의 예시: 키, 달리기, 성적
- 정규분포 예시



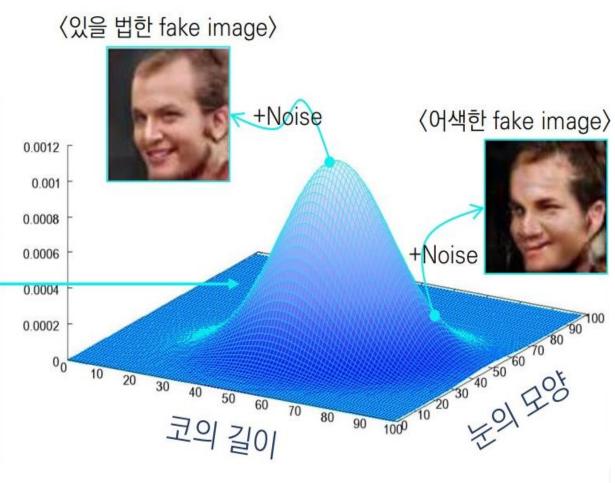
.

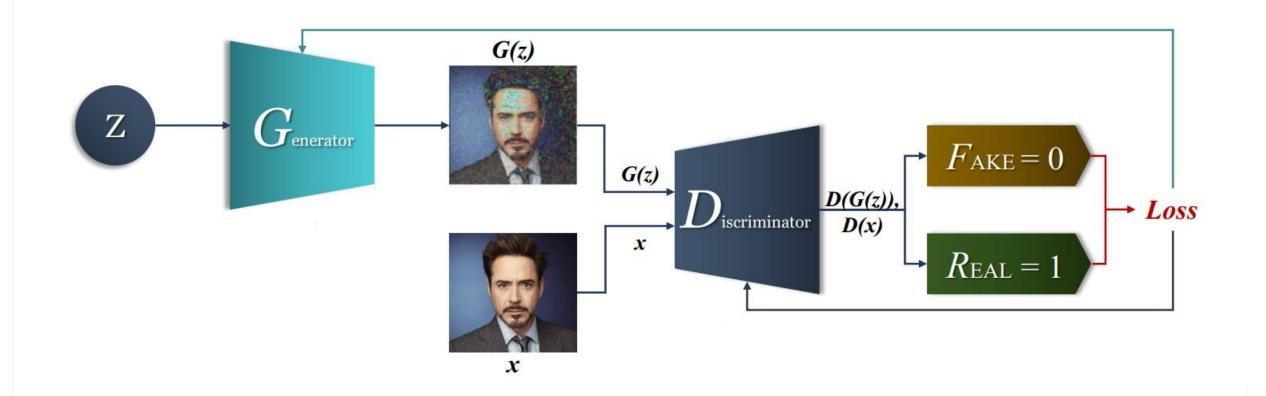
- 실제 많은 데이터들이 정규분포로 표현 가능하다.
- IQ에 대한 정규분포 예시 (표준편차 =24)



- 다변수 확률분포
- 사람 얼굴도 정규분포 표현이 가능하다



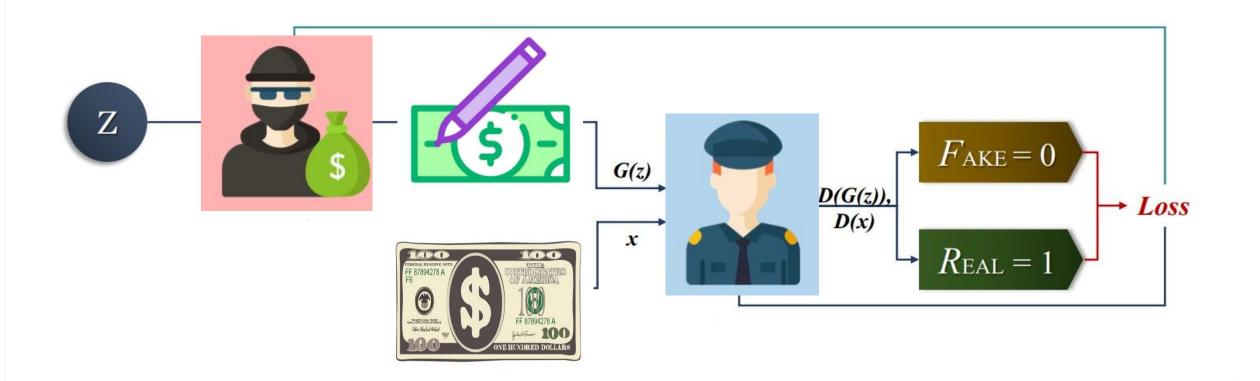


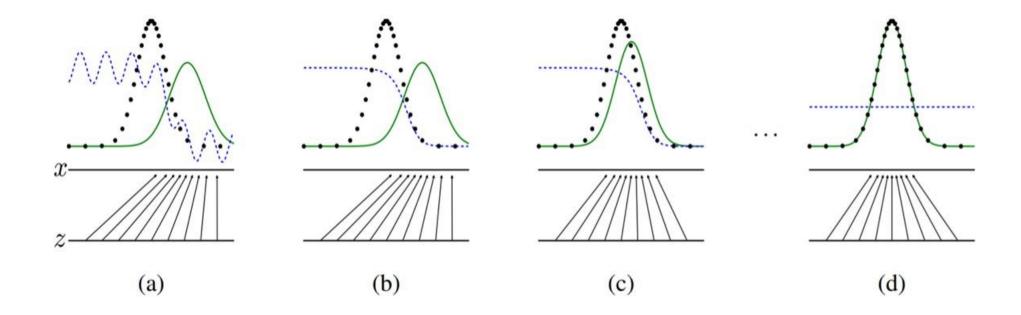


•G: Unsupervised Learning •D: Supervised Learning

D(x): probability (Real:1 ~ Fake:0)

• G(z) : new data instance





- — 원본 데이터의 분포(지폐)
- — 생성 모델의 분포(위조지폐)
- - 판별 모델의 분포.(경찰)

- 목적함수(Objective function)
- D 관점.
- V함수 최대화

$$\min_{G} \max_{D} V(D,G) = E_{x \sim p_{data}(x)}[logD(x)] + E_{z \sim p_{z}(z)}[log(1 - D(G(z)))]$$

• Maximum when D(x) = 1.

• Maximum when D(G(x)) = 0.

- 목적함수(Objective function)
- G 관점.
- V함수 최소화

$$\min_{G} \max_{D} V(D,G) = E_{x \sim p_{data}(x)} [log D(x)] + E_{z \sim p_{z}(z)} [\log(1 - D(G(z)))]$$

• 독립관계. 관여할수없음

• Minimum when D(G(x)) = 1.

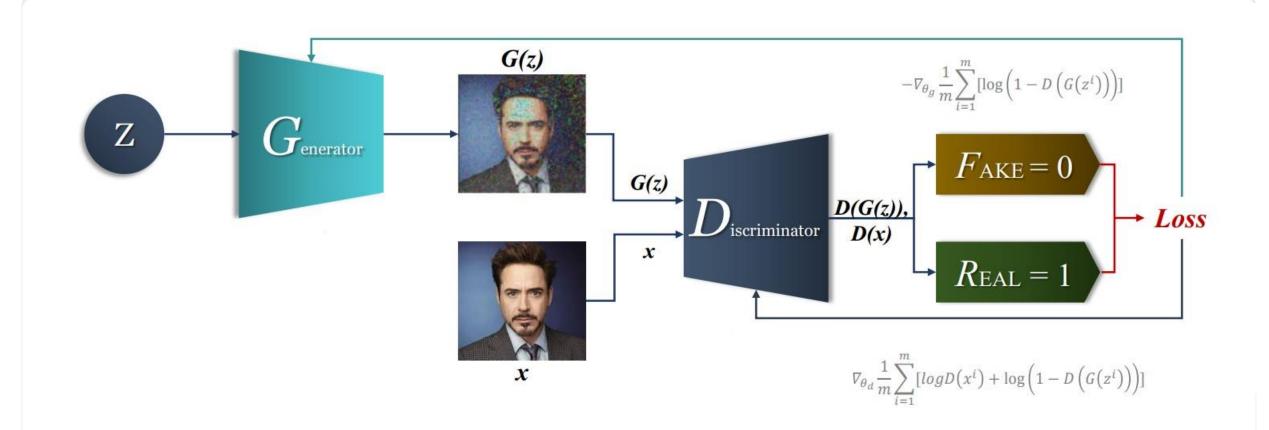
 $F_{\text{AKE}} = 0$

→ Loss

D(G(z)),

 $D_{\text{iscriminator}} D(x)$

G(z)



.

GAN

• 기대값은 모든 사건에 대해 확률을 곱하면서 더하여 계산할 수 있습니다.

이산확률변수에 대한 기대값은 다음의 공식을 통해 계산할 수 있습니다.

$$E[X] = \sum_{i} x_i \cdot f(x_i)$$

연속확률변수에 대한 기대값은 다음의 공식을 통해 계산할 수 있습니다.

$$E[X] = \int x \cdot f(x) dx$$

X : 확률변수

x : 사건

f(x): 확률 분포 함수

GAN

Global Optimality 1

Proposition:
$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

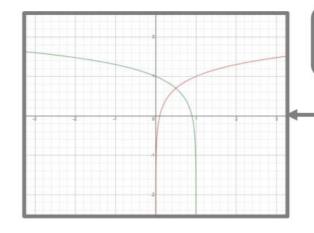
Proof: For G fixed,

$$V(G,D) = E_{x \sim p_{data}(x)}[logD(x)] + E_{z \sim p_{z}(z)}[log(1 - D(G(z)))]$$

$$= \int_{x} p_{data}(x) \log(D(x)) dx + \int_{z} p_{z}(z) \log(1 - D(g(z))) dz$$

$$= \int_{x} p_{data}(x) \log(D(x)) + p_{g}(x) \log(1 - D(x)) dx$$

$$= \int_{x} p_{data}(x) \log(D(x)) + p_{g}(x) \log(1 - D(x)) dx$$



function $y \to alog(y) + blog(1 - y)$ achieves its maximum in [0, 1] at $\frac{a}{a + b}$

same as *optimal control*:
$$\frac{\delta V(G,D)}{\delta D}[D^*(x)] = 0$$

Global Optimality 2

Proposition: Global optimum point is $p_g = p_{data}$

Proof:

$$C(G) = \max_{D} V(G, D) = E_{x \sim p_{data}(x)} [\log D^{*}(x)] + E_{z \sim p_{z}(z)} [\log (1 - D^{*}(G(z)))]$$

$$= E_{x \sim p_{data}(x)} \left[\log \frac{p_{data}(x)}{p_{data}(x) + p_{g}(x)} \right] + E_{x \sim p_{g}(x)} \left[\log \frac{p_{g}(x)}{p_{data}(x) + p_{g}(x)} \right]$$

$$= E_{x \sim p_{data}(x)} \left[\log \frac{2 * p_{data}(x)}{p_{data}(x) + p_{g}(x)} \right] + E_{x \sim p_{g}(x)} \left[\log \frac{2 * p_{g}(x)}{p_{data}(x) + p_{g}(x)} \right]$$

$$= E_{x \sim p_{data}(x)} \left[\log \frac{2 * p_{data}(x)}{p_{data}(x) + p_{g}(x)} \right] + E_{x \sim p_{g}(x)} \left[\log \frac{2 * p_{g}(x)}{p_{data}(x) + p_{g}(x)} \right] - \log(4)$$

$$= KL(p_{data}||p_{g}) - \log(4)$$

$$= 2 * JSD(p_{data}||p_{g}) - \log(4)$$

$$= 2 * JSD(p_{data}||p_{g}) - \log(4)$$

$$= \frac{1}{2}KL(p||\frac{p+q}{2}) + \frac{1}{2}KL(p||\frac{p+q}{2})$$

• 알고리즘

for the number of training iterations do

for k steps do

Sample minibatch of m noise samples $\{z^{(1)}, ..., z^{(m)}\}$ from noise prior $p_g(z)$.

Sample minibatch of m examples $\{x^{(1)}, ..., x^{(m)}\}$ from data generating distribution $p_{data}(x)$.

Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m [log D(x^i) + log (1 - D(G(z^i)))].$$

end for

Sample minibatch of m noise samples $\{z^{(1)}, ..., z^{(m)}\}$ from noise prior $p_g(z)$.

Update the generator by descending its stochastic gradient:

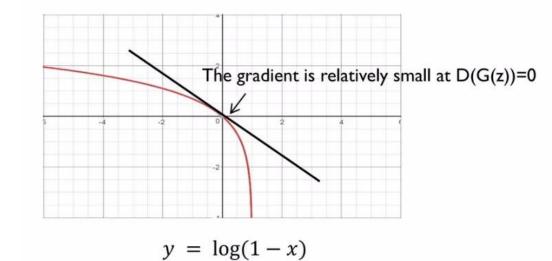
$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log \left(1 - D\left(G(z^i) \right) \right).$$

end for

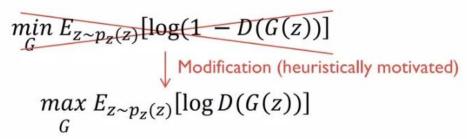
The gradient-based updates can use any standard gradient-based learning rule. They used momentum.

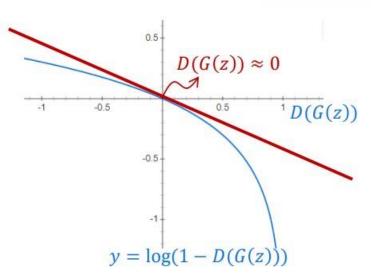
$$\min_{G} E_{z \sim p_{z}(z)}[\log(1 - D(G(z))]$$

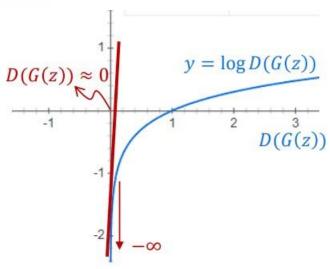




- 학습 초기 G의 성능이 좋지 않기 때문에 $D(G|z|) \approx 0$ 일 확률 이 크다
- 따라서 $D(G|z|) \approx 0$ 에서 Gradient가 이미 작아 학습이 **더딜 가능성이 많다**.







- $\log D(G(z))$ 형태로 변형하면 $D(G(z))\approx 0$ 인 지점이 $-\infty$ 이 되 기 때문에 $D(G(z))\approx 0$ 에서 Gradient가 매우 커지게 된다.
- 따라서 초기 학습속도를 높일 수 있다

• 결과

